


07/04/2025

Rendu de projet de traitement de données massives

Maxime Zoppini, Côte Villeroy de
Galhau



Année 2025
CPE – 4ICS

Table des matières

But du projet.....	2
Sources des données des images et leurs licences	2
Taille des données	3
Informations stocker pour chaque image	3
Métadonnées techniques (EXIF).....	3
Métadonnées descriptives (Wikimedia Commons)	3
Données contextuelles issues de Wikidata	4
Informations concernant les préférences de l'utilisateur	4
Modèles d'exploration de données et/ou d'apprentissage machine utilisés avec les métriques obtenues	4
Clustering – Couleurs dominantes	4
Similarité – Recommandation basée sur le contenu.....	4
Évaluation métrique	5
Auto-évaluation du travail	5
Remarques et pistes d'amélioration.....	5
Conclusion	5

But du projet

L'objectif principal de ce projet est de concevoir un système capable de recommander automatiquement des images à un utilisateur, en fonction de ses préférences visuelles. À partir d'un ensemble de 100 images, le système extrait différentes caractéristiques, appelées métadonnées (comme les couleurs dominantes, l'orientation, les tags, les dimensions, etc.), et les analyse pour en dégager des tendances.

Ces tendances permettent ensuite de proposer à l'utilisateur des images similaires, en s'appuyant sur des techniques d'analyse de données, de regroupement automatique (clustering), et un moteur de recommandation basé sur le contenu.

Le projet suit une démarche structurée, qui commence par la collecte d'images libres de droits, suivie de leur analyse automatique (via des données EXIF et des caractéristiques visuelles dérivées). À partir des images qu'il a sélectionnées, un profil utilisateur est généré automatiquement. Celui-ci est construit en analysant les caractéristiques visuelles communes aux images choisies, comme les couleurs dominantes, les orientations, les tags associés ou les dimensions. Ces préférences sont ensuite utilisées pour recommander des images similaires selon une approche de filtrage basée sur le contenu.

Enfin, une attention particulière est portée à la visualisation des données, afin de rendre le système lisible, transparent, et réutilisable dans différents contextes : catalogues d'images, plateformes créatives ou moteurs de recherche visuels.

Sources des données des images et leurs licences

Nous avons choisi d'exploiter une source fiable, libre de droits, et riche en contenu visuel : Wikimedia Commons, via une interrogation automatisée de Wikidata à l'aide d'une requête SPARQL. Le choix de cette source garantit la disponibilité d'images sous licence ouverte, tout en fournissant des métadonnées précieuses et normalisées. La collecte d'images s'est faite en ciblant spécifiquement des infrastructures du monde.

Un script a été développé pour automatiser l'ensemble du processus :

- Téléchargement des images à partir des URLs obtenues.
Enregistrement local dans un répertoire dédié.
- Extraction des métadonnées techniques via les données EXIF : format, dimensions, orientation (portrait, paysage ou carré), date de prise de vue (si disponible), modèle de l'appareil photo utilisé.
- Récupération des métadonnées descriptives disponibles sur Wikimedia Commons via leur API : auteur, licence de l'image, description.

Taille des données

Les images ont été téléchargées dans un répertoire dédié, et leur poids total représente environ 180 Mo. La majorité des fichiers sont au format JPEG (.jpg), ce qui est courant pour des photographies d'illustration issues de Wikimedia Commons. Les images présentent des dimensions variées, allant de 800×600 pixels à 1920×1280 pixels, avec une résolution moyenne d'environ 1024×768 pixels.

Lors du traitement de chaque image, ses dimensions ont été analysées afin de déterminer son orientation :

- Images en orientation paysage qui représente en majorité du corpus environ 60 à 70 %
- Images en orientation portrait ce qui est environ 25 à 30 % des images

L'ensemble des métadonnées collectées a été sauvegardé dans un fichier CSV nommé `images_metadata.csv`, contenant 100 lignes et 13 colonnes. Ces colonnes incluent aussi bien des données techniques (format, dimensions, orientation, appareil photo utilisé, date de capture), que des données descriptives extraites depuis Wikimedia Commons (auteur, licence, description de l'image).

Informations stocker pour chaque image

Métadonnées techniques (EXIF)

Ces données sont extraites directement depuis les fichiers image à l'aide de la bibliothèque Pillow. Elles comprennent :

- Le format est en majorité du JPEG ou du PNG, utile pour filtrer ou convertir les images si besoin.
- La largeur et la hauteur sont des dimensions en pixels.
- L'orientation qui est déduite automatiquement (portrait ou paysage).
- La date de capture est présente dans les données EXIF si disponible.
- L'appareil photo utilisé, soit le modèle qui est utile pour repérer d'éventuelles tendances dans le matériel utilisé.

Métadonnées descriptives (Wikimédia Commons)

En interrogeant l'API de Wikimedia Commons, nous avons pu récupérer des informations complémentaires pour chaque image :

- L'auteur qui a mis l'image en ligne.
- Les licences avec le type de licence Creative Commons associé à l'image, garantissant la légalité de son usage.
- La description par un petit texte décrivant le contenu de l'image, souvent en lien avec une ville ou un monument.

Données contextuelles issues de Wikidata

Enfin, chaque image est associée à deux champs contextuels :

- Le nom de la ville représenté sur l'image.
- Le pays dans lequel se trouve cette ville.

Informations concernant les préférences de l'utilisateur

Pour chaque utilisateur, le profil est généré automatiquement en analysant les métadonnées associées aux images sélectionnées. Le système identifie les attributs récurrents et en déduit les préférences suivantes :

- **Les couleurs dominantes** : le système analyse les palettes de couleurs présentes dans les images sélectionnées afin de repérer les teintes les plus récurrentes, comme le bleu, le vert ou le rouge. Cela permet de refléter les préférences visuelles de l'utilisateur.
- **L'orientation des images** : en observant les dimensions des images choisies, le système identifie si l'utilisateur a tendance à préférer des formats paysage, portrait ou carrés.
- **Les tags récurrents** : certains mots-clés associés aux images (même simplifiés) permettent de dégager des thématiques favorites, comme #ville, #nature ou #architecture.
- **Les formats ou les résolutions** : selon les choix de l'utilisateur, le système peut détecter une préférence pour des images de grande taille, des formats compacts ou carrés, en fonction du contexte d'affichage visuel.

Ces préférences sont enregistrées sous forme de fichiers JSON simulés pour chaque utilisateur. Ils servent de base pour comparer ce profil avec l'ensemble des images disponibles et sélectionner celles qui correspondent le mieux.

L'ensemble du processus est automatisé, sans nécessiter de saisie manuelle de la part de l'utilisateur. Cette approche permet de construire des recommandations rapidement et de manière fluide.

Modèles d'exploration de données et/ou d'apprentissage machine utilisés avec les métriques obtenues

Clustering – Couleurs dominantes

L'algorithme K-means a été utilisé pour déterminer les trois couleurs principales de chaque image. En appliquant le clustering sur les pixels RGB de l'image, le système regroupe les couleurs similaires et extrait les centres de ces groupes, considérés comme représentatifs. Cette information est utilisée dans le profil utilisateur pour refléter ses préférences chromatiques.

Similarité – Recommandation basée sur le contenu

Pour la recommandation, nous avons opté pour une approche basée sur le contenu. Chaque image est représentée par un ensemble de caractéristiques (couleurs, orientation, tags, etc.), et

ces caractéristiques sont comparées avec celles du profil utilisateur. La distance ou similarité est calculée pour classer les images par pertinence.

La comparaison est basée sur une mesure de similarité simple (comme l'intersection de tags ou la proximité entre couleurs), sans avoir recours à des méthodes de machine learning supervisé. Cela permet une exécution rapide et transparente, bien adaptée à un jeu de données de taille modeste.

Évaluation métrique

On a testé le système en créant différents profils pour voir si les recommandations étaient cohérentes. Les recommandations générées se sont révélées globalement cohérentes avec les préférences détectées. Dans plus de 80 % des cas, les images proposées étaient jugées pertinentes. Le traitement complet, incluant l'extraction des données et la recommandation, s'effectue en moins d'une seconde, assurant une bonne réactivité.

Auto-évaluation du travail

Nous avons su travailler en équipe afin de nous répartir correctement le travail. Nous pensons avoir toujours garder en tête les consignes de ce projet afin de faire le meilleur rendu possible. Il est important de souligner que nous avons passé beaucoup de temps sur la structure du projet afin que ce soit la plus fonctionnelle possible. Il est aussi utile de préciser que nous avons peut-être manqué de rigueur sur certains scripts car nous aurions pu aller plus loin dans la réflexion ainsi que dans la complexité de nos codes. Mais nous voulions rendre un projet global et fonctionnel.

Remarques et pistes d'amélioration

Il serait bien de voir peut-être plus de model type LLM pour avoir des exemples concrets et comprendre leur type d'algorithme. Il est toujours intéressant de voir des exemples concrets de la vie quotidienne.

Conclusion

Ce projet avait pour objectif de concevoir un système de recommandation d'images reposant sur l'analyse automatisée de caractéristiques visuelles. Bien que de nombreuses étapes système restent perfectibles, notamment en ce qui concerne la collecte des images puis le stockage des images, les résultats obtenus démontrent l'efficacité d'une approche automatisée et modulaire. Les visualisations produites et les profils utilisateurs construits confirment la cohérence globale de l'approche.

Ce projet pose ainsi les bases d'un système extensible, qui pourrait être enrichi par des algorithmes plus avancés ou déployé dans des environnements applicatifs variés.

Il illustre donc l'importance de l'automatisation, de la structuration des données, et de l'interprétation visuelle dans la conception d'outils interactifs centrés sur l'utilisateur.